MLOPSDAY BOLOGNA 2026 · COMMUNITY TALK

Il modello non ci sta: le leve per usarlo lo stesso

Qwen3.5-397B-A17B, 209 GB, su un portatile da 48 GB

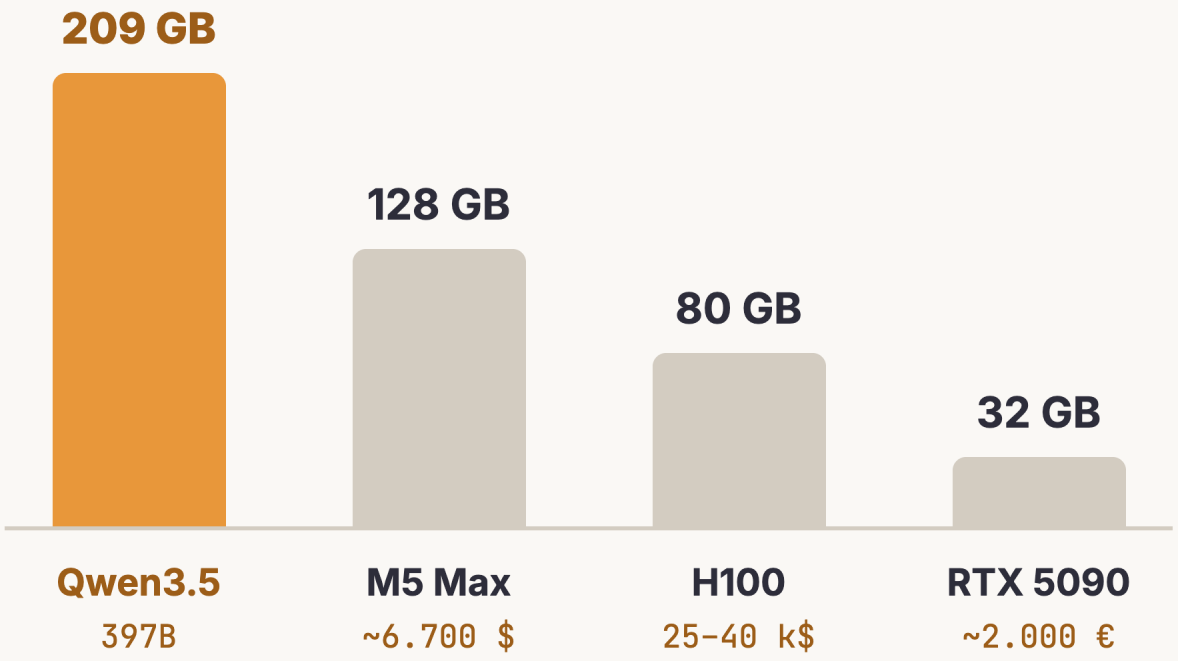
Francesco Montelli

Freelance Software Engineer · montelli.dev

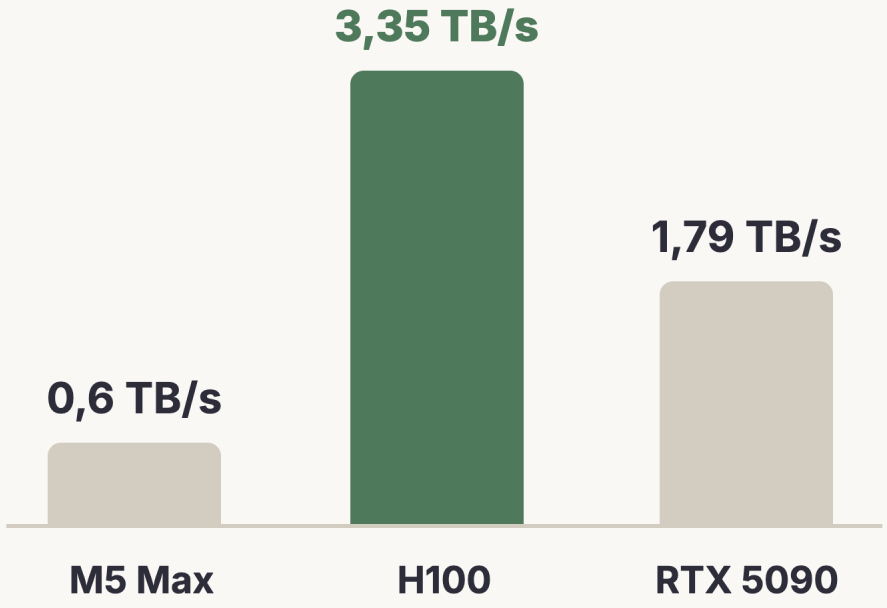
slide
e materiali

Il modello non sta in memoria

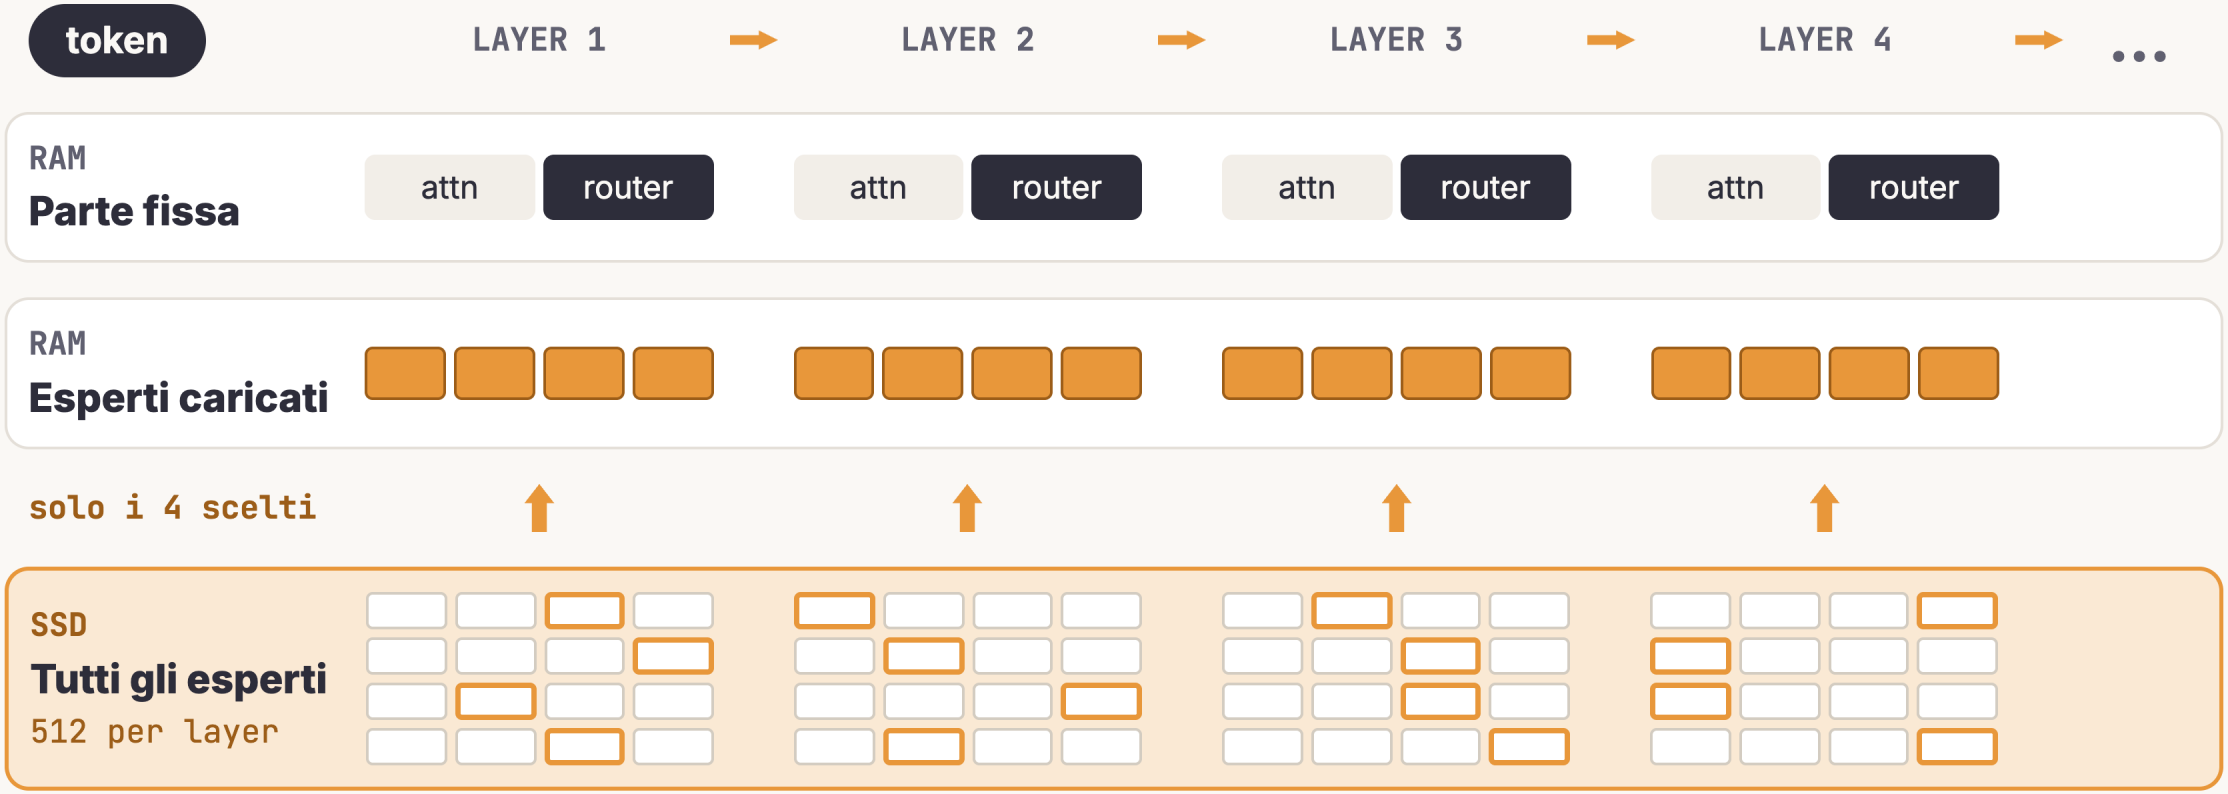
MEMORIA



BANDA



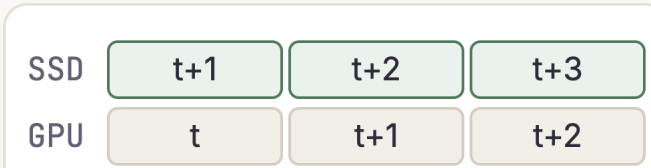
Fissa in RAM, esperti al bisogno



Meno bit, meno byte

BIT	PESO DI QWEN3.5-397B	QUALITÀ
16	≈ 800 GB	originale
8	≈ 400 GB	quasi identica
4	209 GB	lieve perdita
2	120 GB	tool calling rotto

Caricare prima di sapere

STRATEGIA	COME	GUADAGNI	PAGHI
On-demand		**nessun errore**	**attesa a ogni layer**
Speculativo		**niente attesa, se indovini**	**se sbagli, due letture**
Prerouting		**lettura e calcolo insieme**	**il modello cambia un po'**

5 · RIEPILOGO

Tre leve, tre prezzi

LEVA	GUADAGNI	PAGHI
Cache	meno letture da SSD	RAM tolta al resto
I/O	niente page fault	banda contesa con la GPU
Quantizzazione	meno byte per token	tool calling rotto

Non serve più memoria.
Serve sapere cosa tenerci.

Parliamone
francesco@montelli.dev · montelli.dev
github.com/monte97

slide, paper e materiali